Pour des lA Francophones



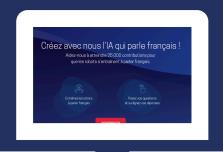
Programme

Rétrospective (3min)

Travaux en cours (10min)

Nos problèmes, vos idées #discussion (10min)

Rétrospective :



Open-source





Rétrospective :

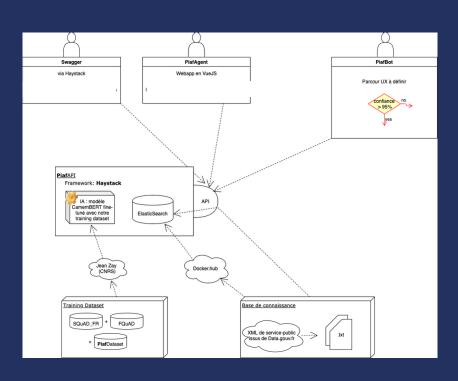
- Micro-travail VS contribution engagée => 🤫
- Ressource native VS multilingue =>

Travaux en cours :

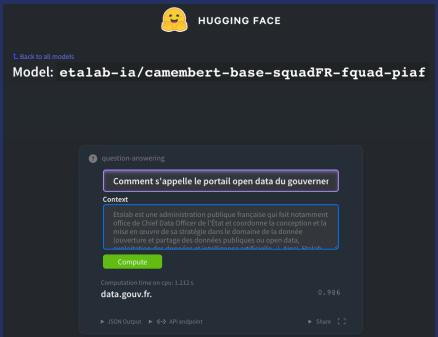
Passer du dataset, à une application clé en main



Travaux en cours:



Travaux en cours : Modèle entraîné



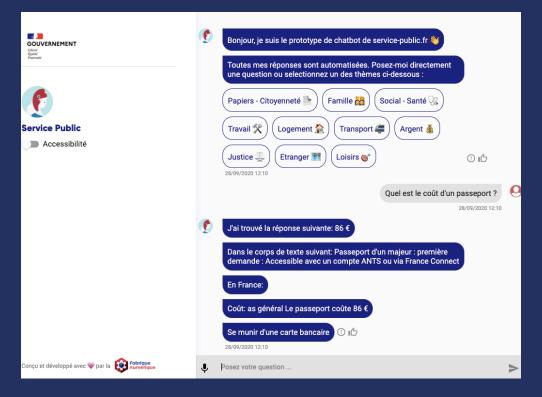
https://huggingface.co/etalab-ia/camembert-base-squadFR-fquad-piaf

Travaux en cours : PiafAgent

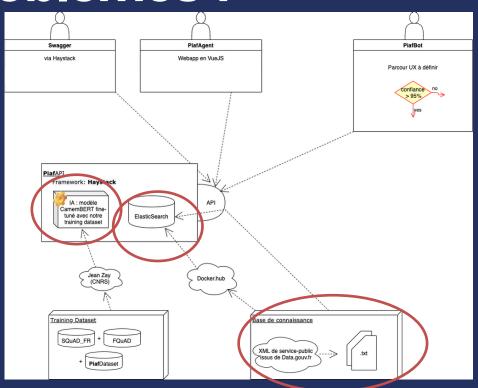




Travaux en cours : PiafBot



Nos problèmes :



Nos pistes actuelles:

- 1. Mesure quanti : BM25 VS Embeddings
- 2. Voir si d'autres modèles de SBERT sont plus performants
- 3. Base de connaissance => que faire pour aider le Reader. Voir si Haystack permet de demander au retriver de chercher dans un texte qui contient les titres et sous-titre, tandis que le Reader ne cherche que dans le texte pur (sans le bruit apporté par les meta infos)
- 4. Mise en place des **filtres**, comme des # par thématique
- 5. Essayer le **DPR**
 - Est qu'on fait une expérience en anglais d'abord ?
 - On demande a Timo de Haystack? Djamé.S? J.Chaumond? code du travail numérique?
 - Regarder ce que ça coûte d'entrainer un DPR en français
- 6. Reader: Utiliser les 25k / fiches de SPF pour fine-tuner CamemBERT?
- 7. Mixer plusieurs retrievers

Questions & Idées ?

Des nouvelles applications?